Tugas Eksplorasi Knime Big Data



Aurelia Fairuz Rachmadi 05111740000141

Dosen:

Abdul Munif, S.Kom, M.Sc..

DEPARTEMEN INFORMATIKA

INSTITUT TEKNOLOGI SEPULUH NOPEMBER

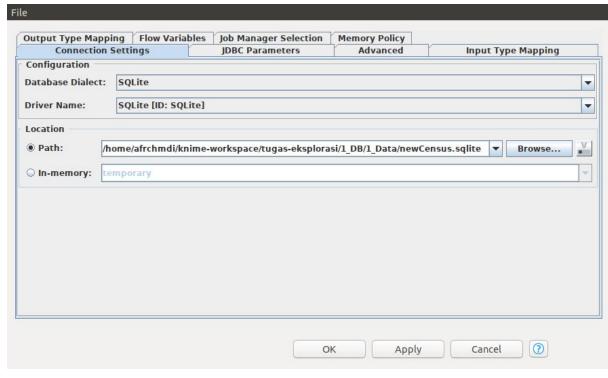
SURABAYA

1_DB

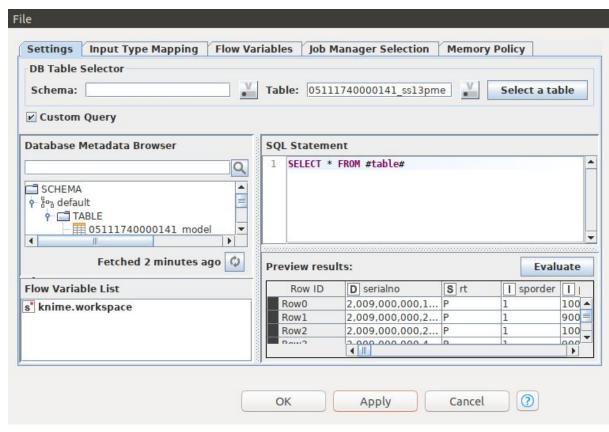
a. 01 DB Connect

Langkah-langkah:

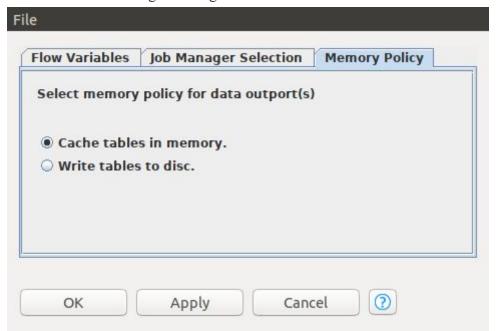
• Membuat koneksi SQLite pada file newCensus.sqlite. Pilih "SQLite Connector" dengan konfigurasi:



• Pilih tabel "05111740000141_ss13pme". Pilih "DB Table Selector" lalu klik "select a table" dengan konfigurasi



Import data yang tersebut pada KNIME data table
Pilih "DB Reader" dengan konfigurasi:



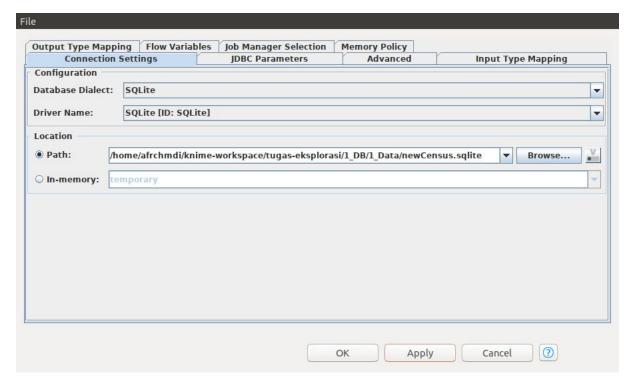
Setelah itu klik kanan lalu pilih "KNIME data table" untuk melihat data

able "data	base" - Rows: 30372	Spe	ec - Columns: 29	95 Proper	rties	low Variables			
Row ID	D serialno	S rt	I sporder	I puma00	I pum	al0 st	I adjinc	I pwgtp	I agep
Row0	2,009,000,000,1	P	1	1000	-9	23	1085467	8	68
Rowl	2,009,000,000,2	Р	1	900	-9	23	1085467	7	51
Row2	2,009,000,000,2	P	1	1000	-9	23	1085467	8	57
Row3	2,009,000,000,4	Р	1	900	-9	23	1085467	32	22
Row4	2,009,000,001,0	P	1	500	-9	23	1085467	23	57
Row5	2,009,000,001,0	P	1	900	-9	23	1085467	23	43
Row6	2,009,000,001,0	P	1	1000	-9	23	1085467	5	27
Row7	2,009,000,001,2	P	1	200	-9	23	1085467	23	22
Row8	2,009,000,001,3	P	1	500	-9	23	1085467	7	69
Row9	2,009,000,001,4	P	1	700	-9	23	1085467	17	47
Row10	2,009,000,001,4	P	1	900	-9	23	1085467	29	43
Rowll	2,009,000,002,0	P	1	800	-9	23	1085467	9	48
Row12	2,009,000,002,2	P	1	200	-9	23	1085467	15	45
Row13	2,009,000,002,7	P	1	200	-9	23	1085467	18	68
Row14	2,009,000,003,0	P	1	800	-9	23	1085467	13	46
Row15	2,009,000,003,1	P	1	900	-9	23	1085467	20	66
Row16	2,009,000,003,2	P	1	100	-9	23	1085467	20	66
Row17	2,009,000,003,6	P	1	800	-9	23	1085467	11	84
Row18	2,009,000,004,3	P	1	1000	-9	23	1085467	20	53
Row19	2,009,000,004,3	P	1	800	-9	23	1085467	23	94
Row20	2,009,000,004,4	P	1	500	-9	23	1085467	5	66
Row21	2,009,000,004,5	P	1	400	-9	23	1085467	93	32
Row22	2,009,000,005,3	P	1	800	-9	23	1085467	7	59
Row23	2,009,000,005,6	P	1	800	-9	23	1085467	6	44
Row24	2,009,000,006,3	P	1	100	-9	23	1085467	26	48
Row25	2,009,000,007,2	P	1	500	-9	23	1085467	9	67
Row26	2,009,000,007,5	P	1	500	-9	23	1085467	24	60
Row27	2,009,000,007,8	P	1	900	-9	23	1085467	20	37
Row28	2,009,000,008,1	P	1	100	-9	23	1085467	30	50
Row29	2,009,000,008,7	P	1	1000	-9	23	1085467	19	59
Row30	2,009,000,009,2	P	1	900	-9	23	1085467	23	42
Row31	2,009,000,009,5	P	1	1000	-9	23	1085467	47	79
Row32	2,009,000,009,6	P	1	1000	-9	23	1085467	5	86
Row33	2,009,000,009,6	P	1	800	-9	23	1085467	7	47
Row34	2,009,000,010,0	P	1	800	-9	23	1085467	12	68

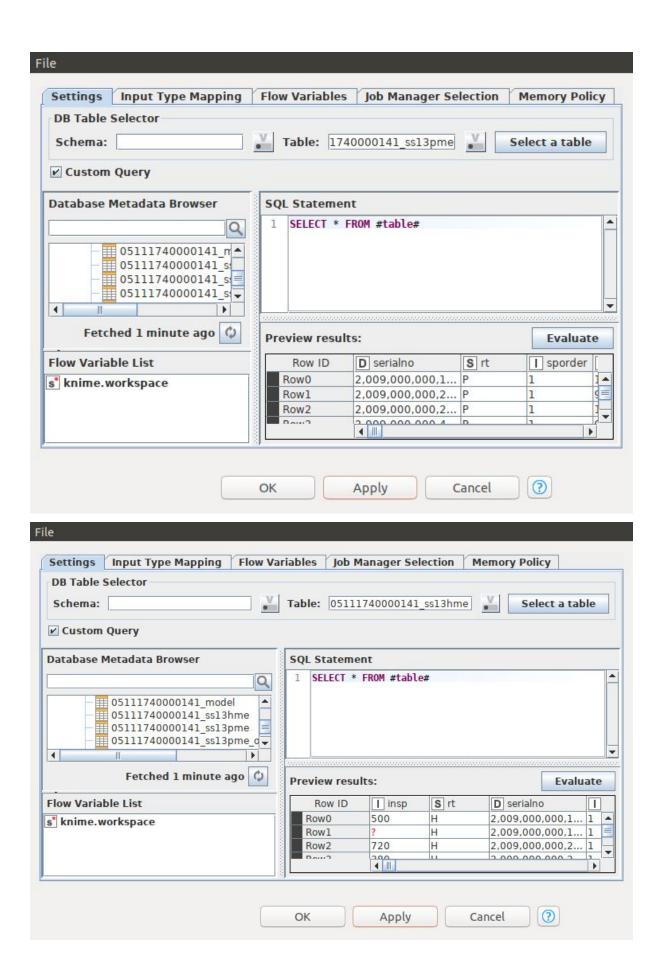
c. 02_DB_InDB_Processing

b.

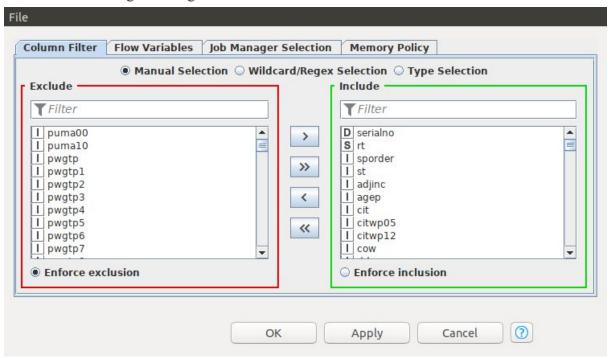
1. Melakukan koneksi database (SQLite) newCensus.sqlite untuk membaca tabel 05111740000141_ss13hme (house data) dan 05111740000141_ss13pme (person data) menggunakan "SQLite Connector" dengan konfigurasi berikut ini:



Setelah itu pilih "DB Table Selector" untuk memilih tabel 05111740000141_ss13hme and 05111740000141_ss13pme

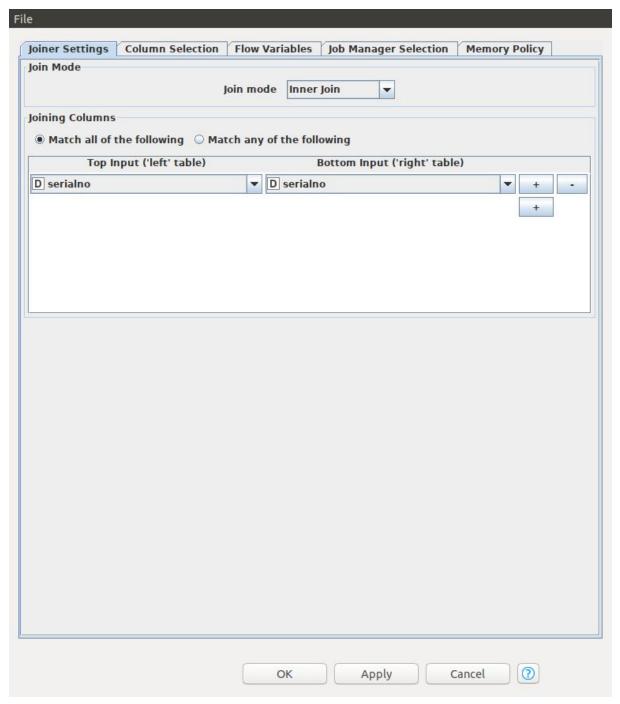


2. Me-remove semua kolom yang bernama PUMA* dan PWGTP* menggunakan "DB Column Filter" dengan konfigurasi

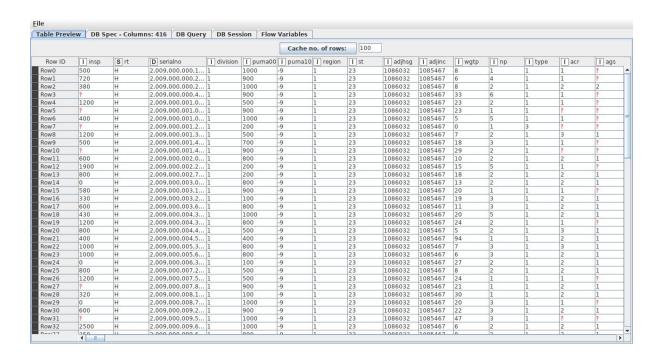


Awalnya table 05111740000141_ss13pme memiliki 295 kolom. Tetapi setelah dilakukan filter menjadi 212 kolom.

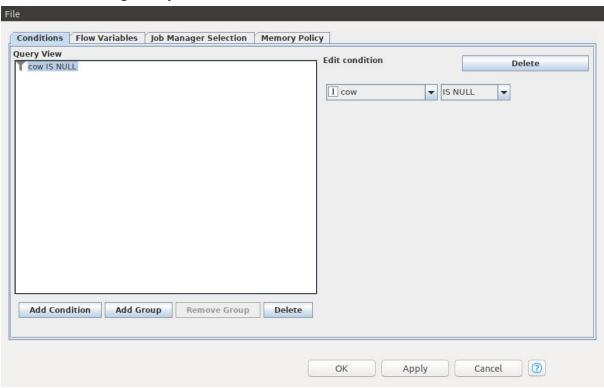
Melakukan Join tabel 05111740000141_ss13hme and 05111740000141_ss13pme pada SERIALNO dengan menggunakan "DB Joiner" dan konfigurasi



Dengan menggunakan inner join serialno pada kedua tabel maka hasil penggabungannya menjadi 416 kolom



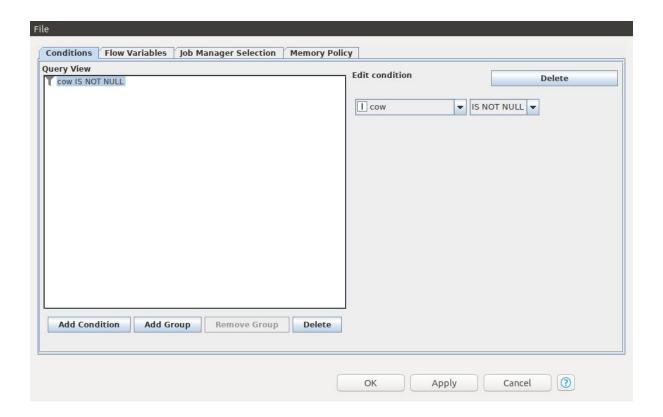
3. Melakukan filter all rows from ss13pme where COW is NULL menggunakan "DB Row Filter". Konfigurasinya:



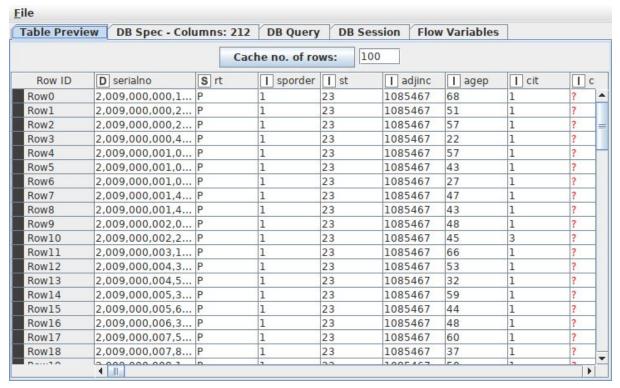
Hasil yang didapat adalah ada sebanyak 8662 data yang COW nya NULL

Table Previe	DB Spec - Colu	ımns: 212	DB Query	/ DB Ses	sion Flo	w Variables			
			Cache no. o	f rows:	100				
Row ID	D serialno	S rt	I sporder	I st	I adjinc	I agep	I cit	Citwp05	5
Row0	2,009,000,001,2	P	1	23	1085467	22	5	?	٦
Rowl	2,009,000,001,3	P	1	23	1085467	69	1	?	Ī
Row2	2,009,000,002,7	P	1	23	1085467	68	1	?	Ī
Row3	2,009,000,003,0	P	1	23	1085467	46	1	?	Ī
Row4	2,009,000,003,2	P	1	23	1085467	66	1	?	Ī
Row5	2,009,000,003,6	P	1	23	1085467	84	1	?	
Row6	2,009,000,004,3	P	1	23	1085467	94	1	?	Ī
Row7	2,009,000,004,4	P	1	23	1085467	66	1	?	
Row8	2,009,000,007,2	P	1	23	1085467	67	1	?	-
Row9	2,009,000,009,5	P	1	23	1085467	79	1	?	_
Row10	2,009,000,010,6	P	1	23	1085467	56	1	?	
Rowll	2,009,000,011,1	P	1	23	1085467	72	4	1987	
Row12	2,009,000,013,4	100	1	23	1085467	75	1	?	
Row13	2,009,000,013,4		1	23	1085467	75	1	?	
Row14	2,009,000,013,6	Р	1	23	1085467	87	1	?	
Row15	2,009,000,016,1	-	1	23	1085467	86	4	1946	-
Row16	2,009,000,018,0		1	23	1085467	89	1	?	-
Row17	2,009,000,018,4		1	23	1085467	77	1	?	
Row18	2,009,000,018,7	2000	1	23	1085467	73	1	?	-
Row19	2,009,000,019,2	Р	1	23	1085467	63	1	?	-
Row20	2,009,000,019,8	50.00	1	23	1085467	94	1	?	
Row21	2,009,000,020,6		1	23	1085467	67	1	?	-
Row22	2,009,000,021,6		1	23	1085467	88	3	?	
Row23	2,009,000,021,6		1	23	1085467	69	1	?	
Row24	2,009,000,022,4	7	1	23	1085467	85	1	?	-
Row25	2,009,000,024,5		1	23	1085467	66	1	?	-
Row26	2,009,000,025,1	2000	1	23	1085467	64	1	?	-
Row27	2,009,000,025,5		1	23	1085467	67	1	?	-
Row28	2,009,000,025,5	0.017	1	23	1085467	70	1	?	
Row29	2,009,000,025,8		1	23	1085467	75	1	?	
Row30	2,009,000,026,4		1	23	1085467	83	4	2006	
Row31	2,009,000,029,2	-	1	23	1085467	75	1	?	
Row32	2,009,000,030,2		1	23	1085467	72	1	?	-
Dam 22	2 000,000 021 5	n	1	22	1005167	02	1	2	

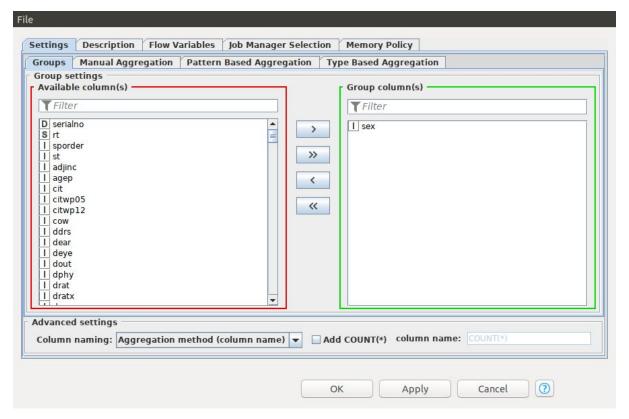
4. Melakukan filter all rows from ss13pme where COW is NOT NULL menggunakan "DB Row Filter". Konfigurasinya:



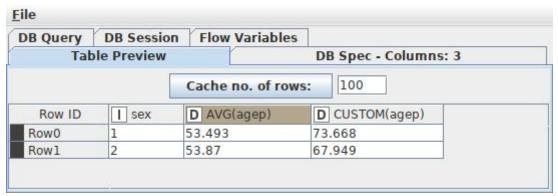
Hasil yang didapat adalah ada sebanyak 21710 data yang COW nya NULL



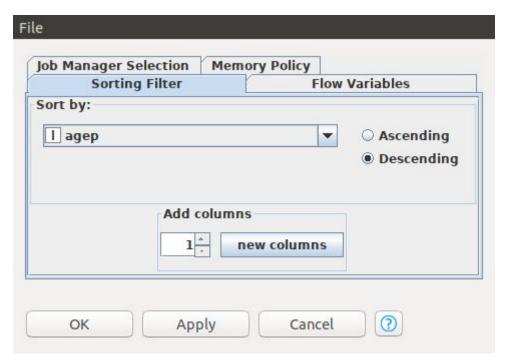
5. calculate average AGEP for the different SEX groups menggunakan "DB GroupBY" dengan konfigurasi berikut ini:



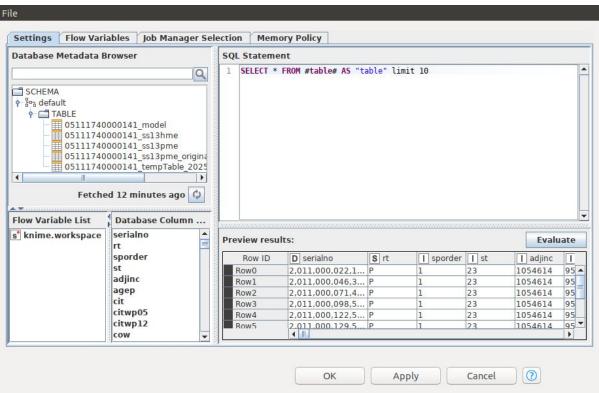
Dan hasil yang diperoleh:



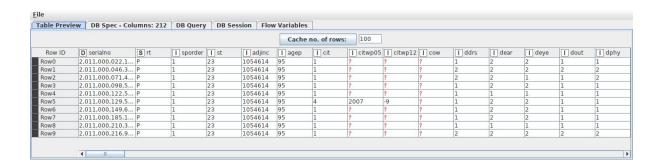
6. Optional. Urutkan baris data secara descending AGEP menggunakan "DB Sorter"



dan ambil 10 teratas menggunakan "DB Query"



Hasilnya:

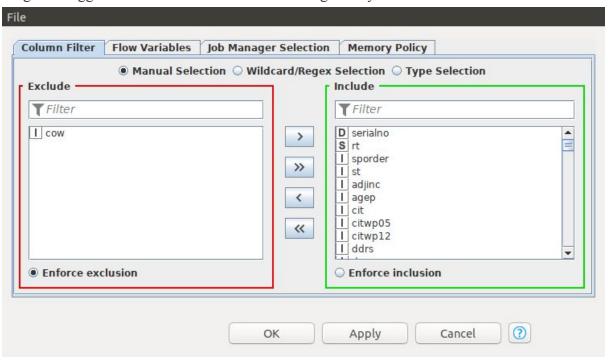


d. 03 DB Modelling

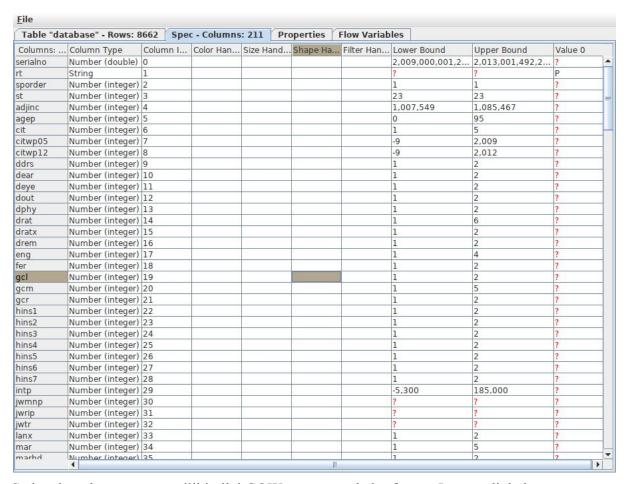
Pada kasus ini mirip seperti "02 DB InDB Processing".

Yang membedakan adalah proses modelling menggunakan algoritma desicion tree untuk melakukan prediksi nilai COW pada kolom COW yang NULL.

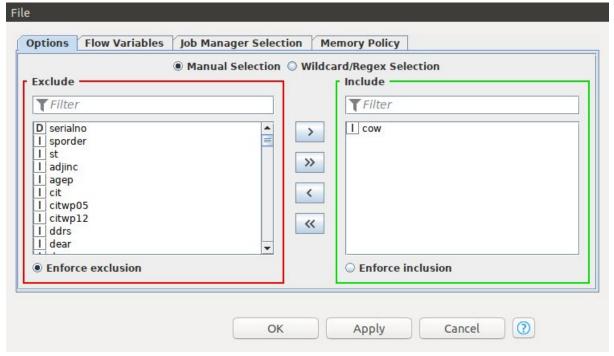
Jika kolom COW nya NULL maka kolom COW tersebut di remove terlebih dahulu dengan menggunakan "DB Column Filter". Konfigurasinya:



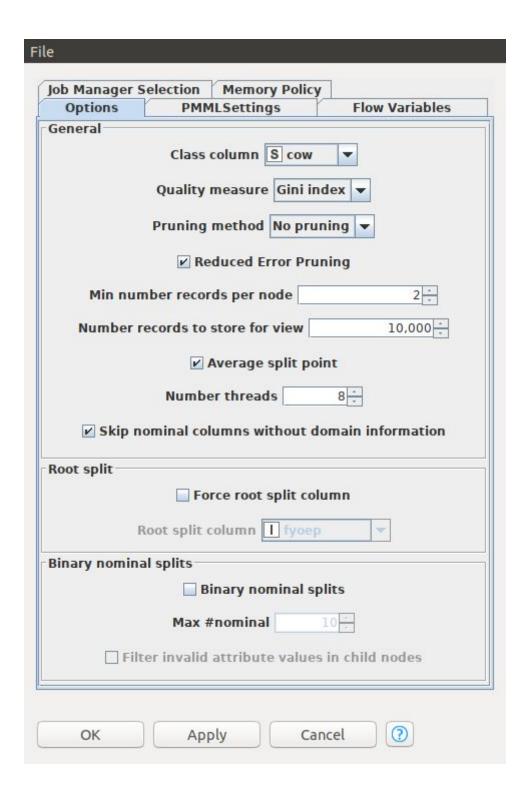
Maka hasilnya tidak ada kolom row pada tabel tersebut:



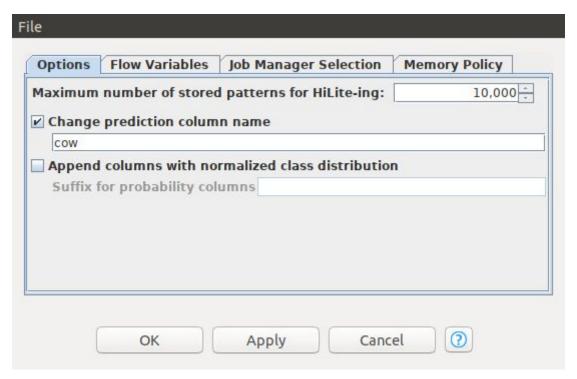
Sedangkan data yang memiliki nilai COW yang semula berformat Integer diubah menjadi String dengan menggunakan "Number to String". Konfigurasinya:



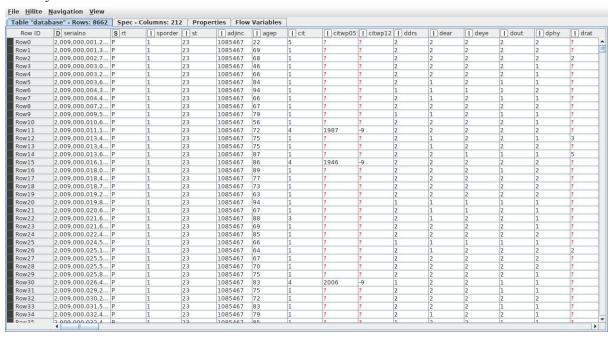
Setelah itu melakukan modelling menggunakan algoritma desicion tree menggunakan "Desicion Tree Learner". Konfigurasinya:



Dari hasil training tersebut dapat dilakukan prediksi menentukan nilai COW yang NULL menggunakan "Desicion Tree Predictor". Berikut konfigurasinya:



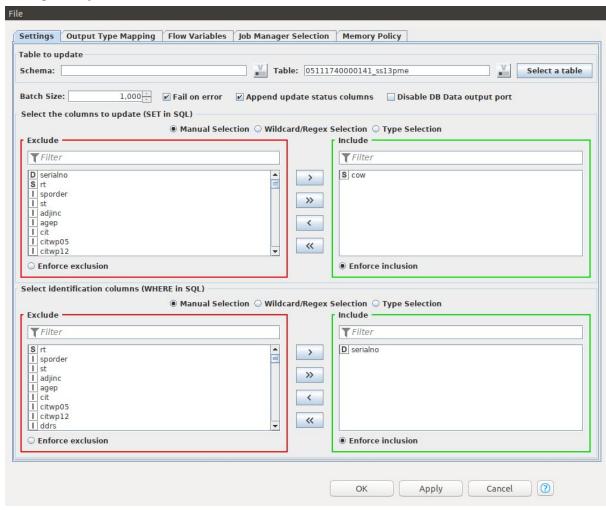
Hasilnya:



e. 04_DB_WritingToDB

Pada bagian ini merupakan penambahan dari bagian "03 DB Modelling". Yaitu:

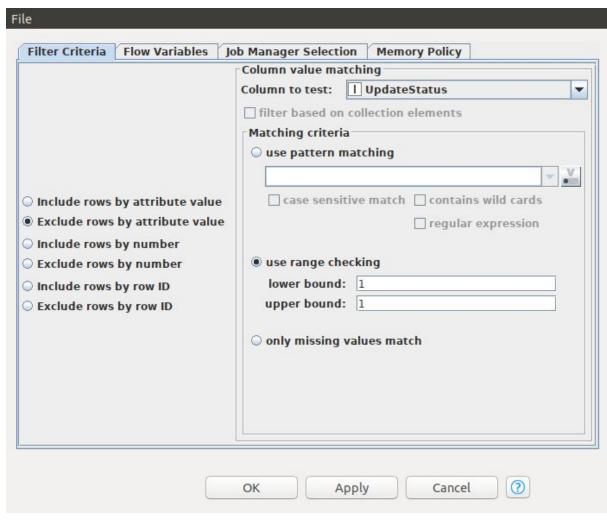
 Tulis prediksi COW yang nilai COW nya NULL menggunakan "DB Update" Konfigurasinya:



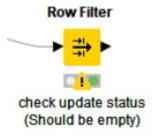
Hasilnya kolom ROW tidak ada yang NULL

 Tulis original table dengan nama tabel 05111740000141_ss13pme_original menggunakan "DB Connection Table Writer".
Untuk memastikan update berhasil maka lakukan configurasi berikut dengan

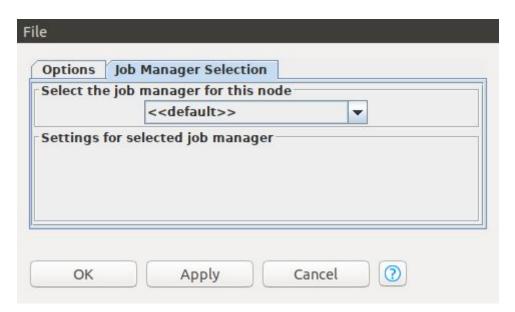
Untuk memastikan update berhasil maka lakukan configurasi berikut dengai menggunakan "Row Filter":



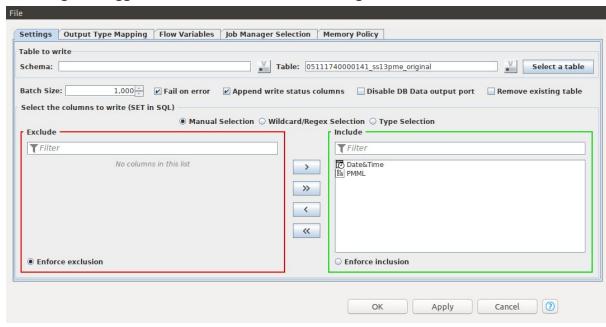
Hasilnya empty:



3. writes model and timestamp with a Database Writer node. Pertama lakukan setting timestamps dengan menggunakan 'timestamp & model'



Lalu dengan menggunakan "DB Writer" lakukan configurasi berikut ini:

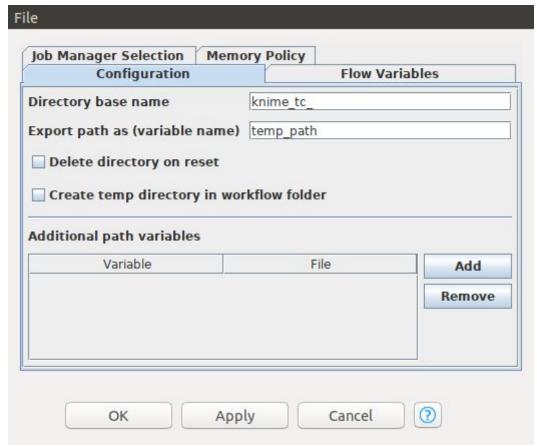


2_Hadoop\2_Exercise

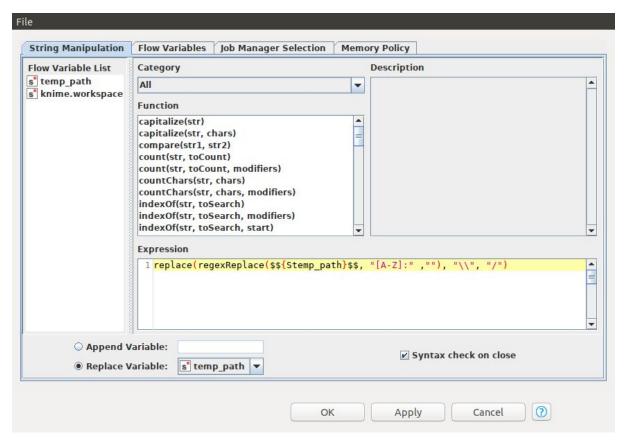
1. 00 Setup Hive Table

Melakukan sets up lingkungan lokal big data lalu load subset pada tabel yang berasal dari file ss13hme.csv dan ss13pme.csv

Pertama kali buat HDFS compatible path dengan membuat "Create Temp Dir". Konfigurasinya:

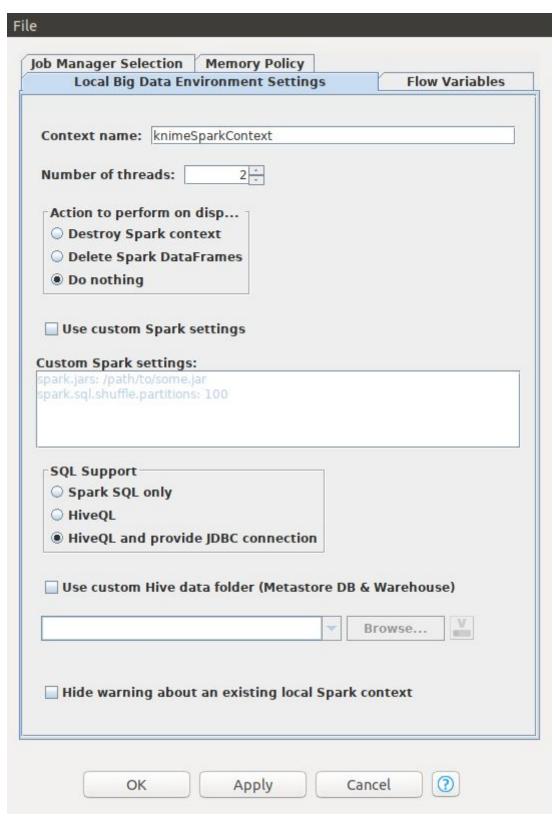


Lalu sambungkan dengan "String Manipulation". Konfigurasinya:



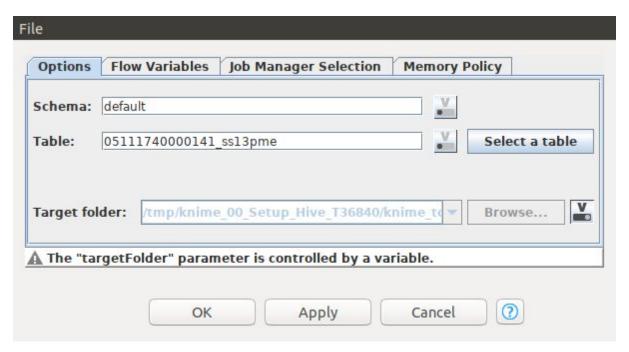
Output dari hasil eksekusi tersebut nantinya akan disambungkan ke "DB Loader"

Kemudian buat "Create Local Big Data Environment" dengan konfigurasi:

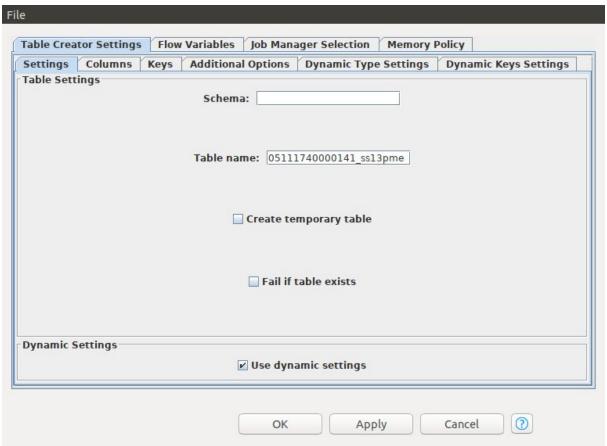


Output nya adalah menghasilkan Hive Connection dan HDFS Connection yang akan connect ke masing-masing "DB Loader"

Untuk membaca file CSV nya maka pertama kali load data menggunakan"Table Reader". Konfigurasinya:



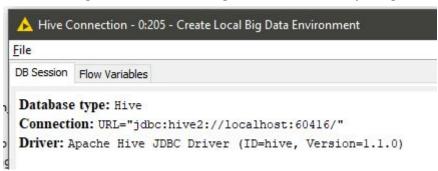
Kemudian membuat DB Table baru dari data sebelumnya dengan konfigurasi:



Setelah itu dengan menggunakan DB Loader maka data akan dapat ditampilkan pada database.

Untuk melihat hasilnya:

- a. Buka DBeaver
- b. Buat koneksi "New Database Connection"
- c. Pilih "Apache Hive"
- d. Setting port yang digunakan. Sesuaikan dengan port yang ada pada "Hive Connection" pada Create Local Big Data Environment yaitu port 60416



Generic JDBC Connection Settings

Database connection settings.



JDBC URL:	jdbc:hive2://localhost:45543	
Host:	localhost	Port: 45543
Database/Schema:		
User name:		
Password:		✓ Save password local
© V	hl i	
① You can use varia	ables in connection parameters.	Connection details (name, type,
① You can use varia	**************************************	Connection details (name, type,

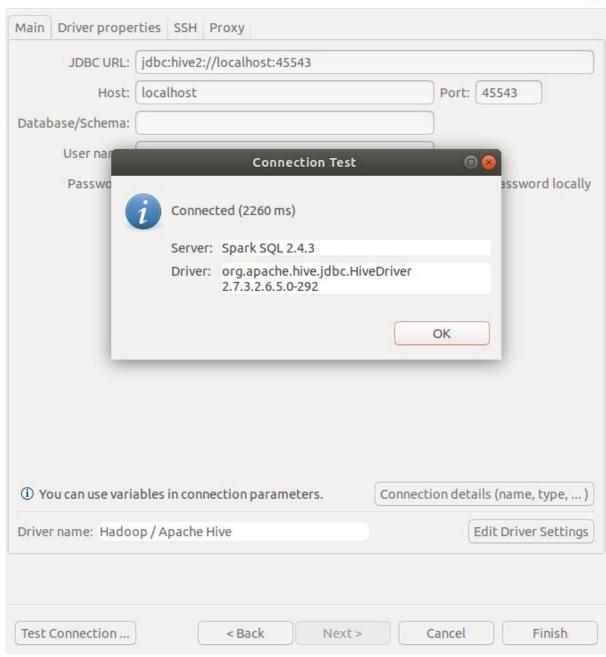
e. Lakukan Test Connection untuk memastikan koneksi dapat dilakukan

Connect to database

Generic JDBC Connection Settings

Database connection settings.

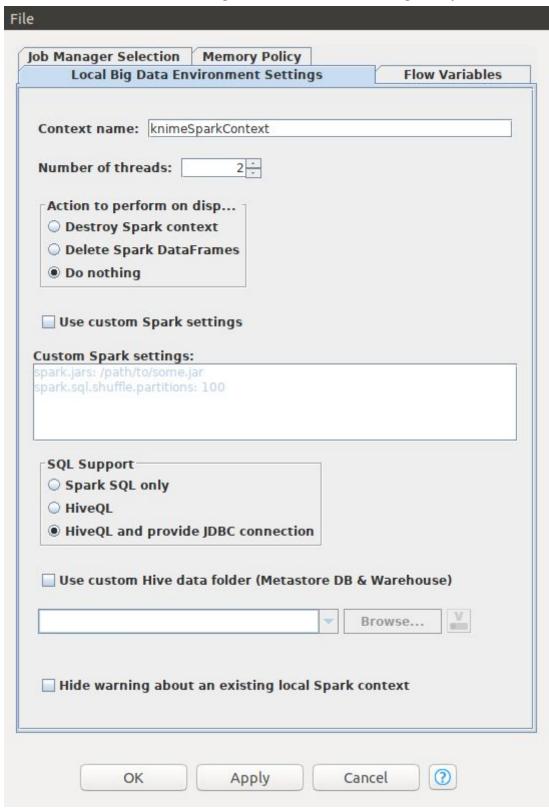




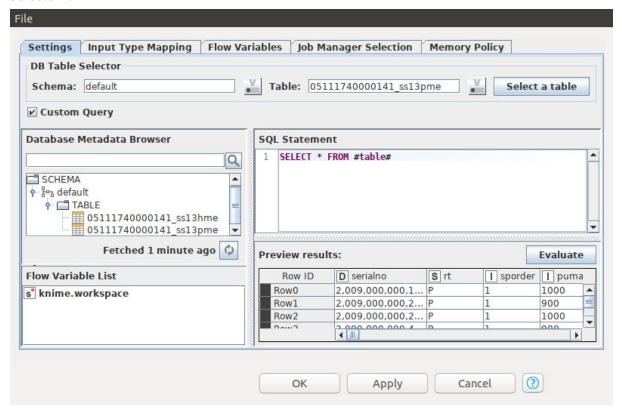
2. 01 Hive Modelling

Setelah koneksi berhasil dibuat dan data telah tersimpan dalam database maka pada tahap ini akan dilakukan modelling data dengan menggunakan algoritma Desicion Tree

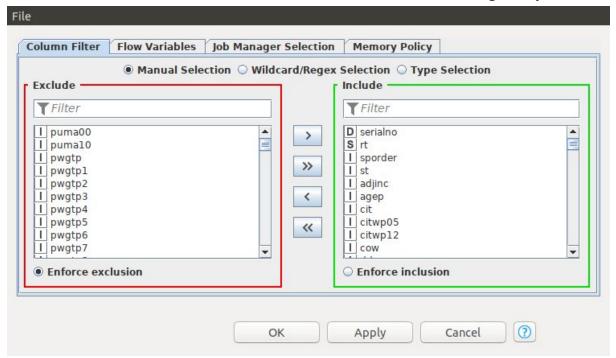
Pertama lakukan "Create Local Big Data Environment". Konfigurasinya:



Setelah itu pilih tabel 05111740000141_ss13pme dengan menggunakan "DB Table Selector".



Lakukan filter kolom untuk me remove kolom PUMA* & PWGTP*. Konfigurasinya:



Awalnya table 05111740000141_ss13pme memiliki 295 kolom. Tetapi setelah dilakukan filter menjadi 212 kolom.

Selanjutnya melakukan filter all rows from ss13pme where COW is NULL menggunakan "DB Row Filter".

Hasil yang didapat adalah ada sebanyak 8662 data yang COW nya NULL

Lalu melakukan filter all rows from ss13pme where COW is NOT NULL menggunakan "DB Row Filter".

Hasil yang didapat adalah ada sebanyak 21710 data yang COW nya NULL

Jika kolom COW nya NULL maka kolom COW tersebut di remove terlebih dahulu dengan menggunakan "DB Column Filter".

Maka hasilnya tidak ada kolom row pada tabel tersebut.

Sedangkan data yang memiliki nilai COW yang semula berformat Integer diubah menjadi String dengan menggunakan "Number to String".

Setelah itu melakukan modelling menggunakan algoritma desicion tree menggunakan "Desicion Tree Learner".

Dari hasil training tersebut dapat dilakukan prediksi menentukan nilai COW yang NULL menggunakan "Desicion Tree Predictor". Berikut konfigurasinya:

3. 02 Hive WritingToDB

- 1. It reads data from local Hive;
- 2. it selects table ss13pme;
- 3. it isolates rows with missing cow value and rows with not missing cow values;
- 4. it imports the data into KNIME;
- 5. it creates a model to predict values for cow;
- 6. it uses cow predictions to override missing income values;
- 7. it rebuilds the datasets with the predicted cow values instead of the missing values
- 8. it writes the results back into Hive.

Pada subbab ini akan dilakukan override missing income values menggunakan cow predictions dan menyimpannya bersama data training cow learner ke dalam database Hive

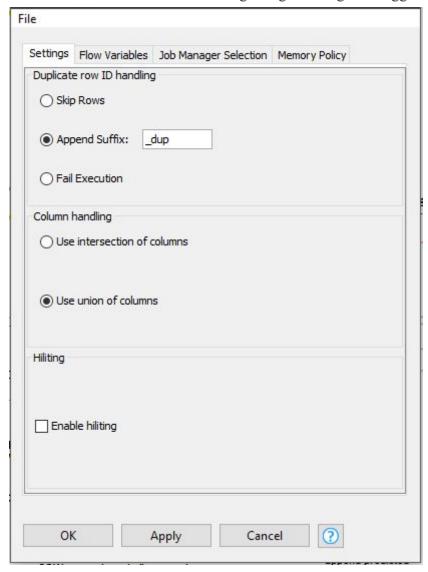
Pertama kali buat HDFS compatible path dengan membuat "Create Temp Dir". Lalu sambungkan dengan "String Manipulation".

Output dari hasil eksekusi tersebut nantinya akan disambungkan ke "DB Loader"

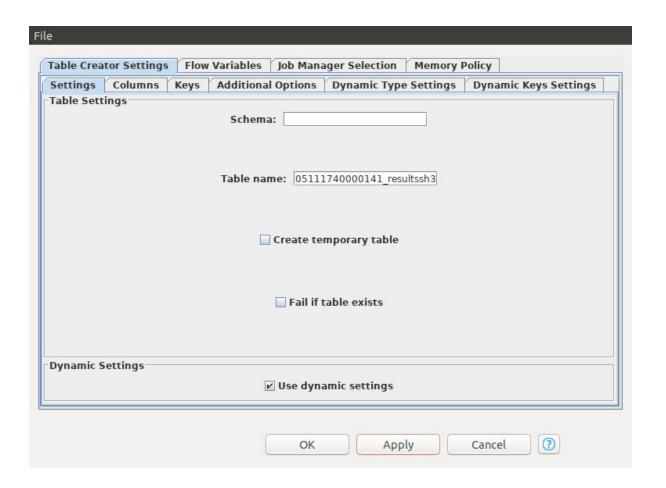
Kemudian buat "Create Local Big Data Environment" dengan konfigurasi:

Output nya adalah menghasilkan Hive Connection dan HDFS Connection yang akan connect ke "DB Loader" dan "DB Table Creator"

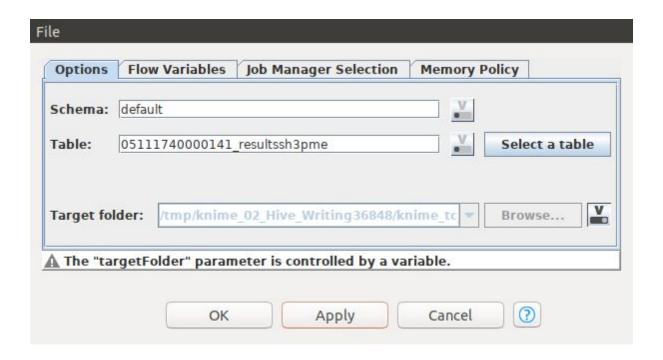
Hasil data train dan data test akan digabungkan dengan menggunakan "Concatenate".



Setelah itu akan dibuat tabel baru menggunakan "DB Table Creator" dengan input hasil concatenate (Data table) dan DB Connection pada Local Big Data Environment. Tabel baru tersebut saya beri nama "05111740000141_resultssh3pme". Konfigurasinya:



Setelah table database berhasil dibuat maka outputnya akan dijadikan input pada "DB Loader" sebagai DB Connection bersama dengan Create Local Big Data Environment (Connection information port), Concatenate (Data to load into database), dan String Manipulation (Variable Inport). Konfigurasinya:



Link Github https://github.com/afrchmdi/Tugas-Eksplorasi-KNIME-Big-Data